AICB-P1 · NGÀY 8 · PRODUCTION MINI

RAG Pipeline

Từ vector store demo đến pipeline đo được và giải thích được trong môi trường công ty.

Indexing Retrieval Generation

Policy + Helpdesk assistant → Pipeline đo được → Scorecard

SLA ticket P1?

GROUNDED ANSWER

"Theo **support/sla-p1-2026.pdf**, ticket P1 có SLA phản hồi 15 phút và xử lý trong 4 giờ."

Instructor

[Tên giảng viên]

[Chức danh / vai trò]

- [Kinh nghiệm 1]
- [Kinh nghiệm 2]
- [Kinh nghiệm 3]
- [Kinh nghiệm 4]

> **Bối cảnh buổi học hôm nay**
>
> Artifact xuyên suốt là **trợ lý nội bộ cho khối CS + IT Helpdesk**: trả lời policy, workflow cấp quyền và SLA ticket bằng chứng cứ được retrieve có kiểm soát.

Policy docs **Ticket SLA** **Grounded answers**

Có vector store rồi, vì sao agent vẫn trả lời sai?

Đặt vấn đề mở bài theo đúng tinh thần source PDF

HALLUCINATE

Câu trả lời có vẻ đúng văn phong, nhưng sai nội dung.

VÍ DỤ SAI

"Ticket P1 có SLA xử lý trong 8 giờ làm việc."

RETRIEVED CHUNK #1

support/sla-p1-2024.pdf · "P1 xử lý trong 8 giờ..."

RETRIEVED CHUNK #2

ticket-guide-old.md · thiếu metadata effective_date

Indexing lỗi

Chunk sai, metadata thiếu hoặc tài liệu cũ khiến retrieval lệch từ rất sớm.

Retrieval lỗi

Query lệch, top-k nhiễu, dense-only miss keyword, hoặc lấy trùng lặp quá nhiều.

Generation lỗi

Prompt không grounded, context quá nhiều hoặc model tự điền khoảng trống bằng suy diễn.

Thông điệp thực dụng

Đừng nhảy ngay sang đổi model. Hãy kiểm tra lần lượt **index** → **retrieval** → **prompt grounding**.

Mục tiêu học tập & đầu ra cuối ngày

Học gì trong 4 giờ lý thuyết và build gì trong 4 giờ thực hành

Learn

- Hiểu RAG như pipeline: indexing → retrieval → rerank/select → generation
- So sánh dense / sparse / hybrid và biết khi nào cần rerank
- Thiết kế prompt grounding và đánh giá bằng scorecard

Build

- Full RAG pipeline với index, retrieval và answer function grounded
- 10 test questions có expected answer / expected evidence
- Scorecard baseline vs tuning + docs kỹ thuật nhóm

Hoạt động 1 — Error Tree

Chẩn đoán lỗi trong một case RAG trả lời sai

8 PHÚT THẢO LUẬN

CASE

"SLA xử lý ticket P1?"

Agent trả lời theo doc cũ. Nhóm hãy đưa ra **1 giả thuyết lỗi** và **1 cách kiểm tra nhanh**.

Output mong đợi

1 error tree ngắn: indexing / retrieval / generation + cách kiểm tra giả thuyết tương ứng.

Nhóm 3–4 người 2 phút chia sẻ

Worksheet board

Indexing

Doc cũ hoặc thiếu **effective_date** nên lọc sai phiên bản.

Kiểm tra: list metadata của top chunks.

Retrieval

Dense-only bỏ lỡ exact term "P1" hoặc lấy top-k nhiều noise.

Kiểm tra: compare dense vs hybrid và log top-5 chunks.

Generation

Prompt không ép citation nên model lấp chỗ trống bằng suy đoán.

Kiểm tra: answer only from context, if insufficient say unknown.

RAG = 3 pipeline phối hợp

Search engine + LLM, không phải chỉ là “gắn thêm context”

Indexing

- Preprocess
- Chunk
- Embed + Store

Retrieval

- Search
- Rerank
- Select

Generation

- Prompt + Context
- Answer
- Citation

RAW DOCS

refund-v4.pdf
access-control-sop.md
sla-p1-2026.pdf

RETRIEVED EVIDENCE

top chunks có source, section, score

FINAL ANSWER

Answer grounded + citation + biết từ chối khi thiếu chứng cứ

Mental model

Indexing chuẩn bị chứng cứ. Retrieval chọn chứng cứ. Generation diễn giải chứng cứ thành câu trả lời dùng được.

Indexing pipeline chuẩn: chunk đúng, metadata rõ, freshness có kiểm soát

Chất lượng retrieval bắt đầu từ lúc chuẩn bị tài liệu

Document
PDF, HTML, bảng, OCR

→

Preprocess
Clean, extract, normalize

→

Chunk
Heading, boundary, overlap

→

Embed
Vector hoá nội dung

→

Store
Text + vector + metadata

3 quyết định quan trọng

- Preprocess trước khi embed: bỏ OCR lỗi, bảng vỡ, ký tự rác
- Chunk theo heading / section tự nhiên, overlap vừa đủ
- Metadata + effective_date + access giúp lọc đúng phạm vi

Metadata hữu ích

source · section · effective_date · department · access

```
metadata = { source: "policy/refund-v4.pdf", section: "Điều 3", department: "CS", effective_date: "2026-02-01", access: "internal" }
```

BATCH UPDATE

- Đơn giản, rẻ
- Phù hợp policy docs

NEAR REAL-TIME

- Giảm stale answers
- Cần retry + queue

Hoạt động 2 — Chunking clinic

Từ một policy doc, đề xuất chunk size / overlap / metadata tối thiểu

BAD CHUNK

Điều kiện hoàn tiền được áp dụng khi...

... khách hàng gửi yêu cầu trong vòng **7 ngày** làm việc kể từ thời điểm xác nhận...

- Cắt giữa điều khoản
- Mất source / section
- Dễ làm retriever hiểu thiếu ngữ cảnh

GOOD CHUNK

Hoàn tiền — Điều kiện áp dụng
Yêu cầu được gửi trong vòng **7 ngày** kể từ thời điểm xác nhận đơn hàng.
Source: policy/refund-v4.pdf · Điều 3 · effective_date 2026-02-01

- Cắt theo heading / section tự nhiên
- Có overlap vừa đủ
- Giữ source, section, date

Quyết định	Nhóm đề xuất	Lý do
Chunk size	300–500 tokens	Giữ trọn section, tránh nhét nhiều ý không liên quan
Overlap	50–80 tokens	Không đứt mạch ý ở ranh giới chunk
Metadata tối thiểu	source, section, effective_date	Phục vụ filter, freshness và citation

Dense, Sparse hay Hybrid?

Chọn chiến lược retrieval theo dạng dữ liệu và dạng query

VÍ DỤ CHUNG

Query: “refund trong 7 ngày”

Dense

Mạnh ở: nghĩa, paraphrase

Hay hụt: mã lỗi, keyword hiếm

Khi dùng: corpora nhiều câu tự nhiên

Sparse

Mạnh ở: exact term, tên riêng

Hay hụt: câu hỏi paraphrase

Khi dùng: policy, code, mã ticket

Hybrid

Mạnh ở: giữ nghĩa lẫn keyword

Đổi lại: cần tuning weight ban đầu

Khi dùng: enterprise docs lẫn lộn

Thông điệp practical

Nếu corpus có cả ngôn ngữ tự nhiên lẫn tên riêng, mã lỗi, điều khoản hoặc ký hiệu, **hybrid** là điểm bắt đầu rất đáng thử.

Hoạt động 3 — Chọn chiến lược retrieval

Query nào nên dùng dense, sparse hay hybrid?

QUERY A

“Khách hàng có thể hoàn tiền nếu đổi lịch giao hàng sau khi đã xác nhận không?”

Câu tự nhiên dài, paraphrase nhiều ý.

Dense Sparse Hybrid

QUERY B

“ERR-403-AUTH” hoặc “P1”

Chứa exact term, mã lỗi, ticket code.

Dense Sparse Hybrid

QUERY C

“Approval Matrix” nhưng doc mới đổi tên thành “Access Control SOP”

Có alias hoặc tên cũ.

Dense Sparse Hybrid

Query transformation, top-k và rerank funnel

Lấy rộng để không bỏ sót, chọn lại để bớt nhiễu

EXPANSION

Thêm từ đồng nghĩa, alias hoặc tên cũ để tăng recall.

DECOMPOSITION

Tách query phức tạp thành 2–3 truy vấn nhỏ dễ tìm hơn.

HYDE

Sinh câu trả lời giả định để tăng tín hiệu semantic khi search.

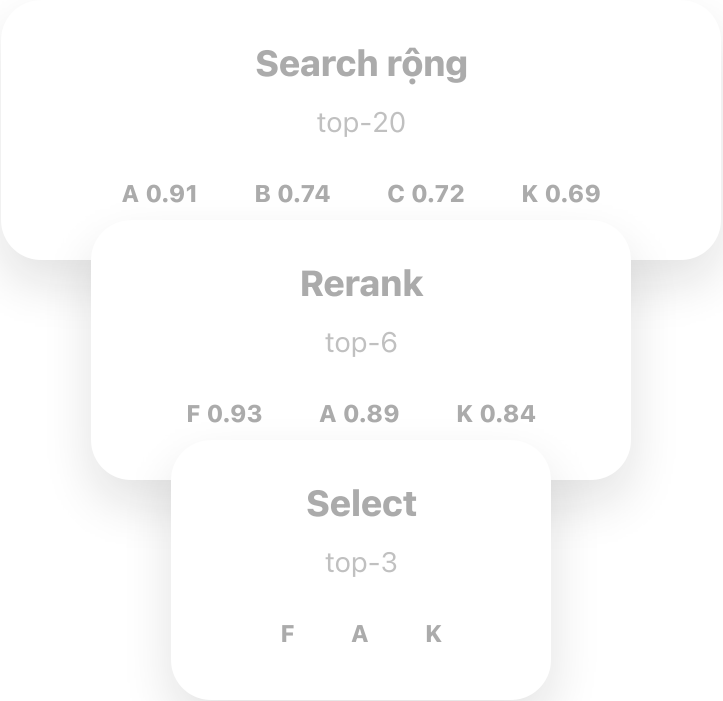

Top-k sweet spot

Mục tiêu của retrieval không phải lấy nhiều, mà là lấy **đúng và đủ** cho generation.

k quá thấp → recall kém

k vừa đủ → top-3 đến top-5

k quá cao → nhiễu, tốn token

Cross-encoder chấm lại độ liên quan. **MMR** giữ relevance nhưng giảm trùng lặp.

Inject context đúng cách để model bớt bịa

Grounded generation đến từ cách đóng gói evidence, không phải nhét thật nhiều text

Prepend

Đặt toàn bộ context lên đầu prompt. Dễ làm nhưng khó kiểm soát.

Structured snippets

Mỗi chunk có source, section, score. Dễ đọc và dễ citation hơn.

Citation blocks

Evidence blocks riêng biệt để model trích dẫn trực tiếp.

Instruction | Context | Question | Headroom

Token budget: Context chiếm gần hết cửa sổ token sẽ làm tăng lost in the middle và mâu thuẫn giữa nguồn.

grounded_prompt.txt

```
Answer only from the retrieved context.
If the context is insufficient, say you do not know.
Cite the source field when possible.

Question: SLA xử lý ticket P1?

Context:
[1] support/sla-p1-2026.pdf | Section 2 | score=0.93
P1: phản hồi 15 phút, xử lý trong 4 giờ.

[2] it/access-control-sop.md | Section 4 | score=0.84
Escalation chỉ áp dụng khi cần thay đổi quyền hệ thống.
```

Kết quả mong muốn

"Theo **support/sla-p1-2026.pdf**, P1 có SLA phản hồi 15 phút và xử lý trong 4 giờ. Nếu cần escalation, áp dụng theo SOP cấp quyền."

Hoạt động 4 — Prompt surgery

Biến một prompt xấu thành grounded prompt

Prompt xấu

```
Hãy trả lời thật tự tin.
Dùng kiến thức của bạn để lấp chỗ trống.

Question: {query}
Context: {context_block}

Không cần trích nguồn.
```

Grounded prompt

```
Answer only from the retrieved context.
If evidence is insufficient, say you do not
know.
Cite source / section when possible.
Keep output short, clear, and factual.

Question: {query}
Context: {context_block}
```

Evidence-only
Không cho model bịa thêm

Abstain
Thiếu dữ liệu thì nói rõ

Citation
Buộc output gắn nguồn

Format
Ngắn, rõ, nhất quán

Task

Làm cá nhân 5 phút → chia sẻ nhóm 5 phút → ra 1 prompt template chung.

Đo RAG bằng scorecard, không bằng cảm giác

Faithfulness, relevance, context recall/completeness và A/B tuning

Faithfulness

Câu trả lời có bám đúng chứng cứ đã retrieve không?

Answer relevance

Có trả lời đúng câu hỏi người dùng hỏi không?

Context recall

Retriever có mang về đủ evidence cần thiết không?

Completeness

Có thiếu điều kiện ngoại lệ hoặc bước quan trọng không?

A/B rule

Chỉ đổi **một biến mỗi lần** để biết điều gì thực sự tạo ra cải thiện.

Test question	Faithful	Relevant	Complete	Ghi chú
Chính sách hoàn tiền 7 ngày?	4/5	5/5	4/5	Thiếu điều kiện ngoại lệ
Ai duyệt yêu cầu cấp quyền?	5/5	4/5	3/5	Đúng nguồn nhưng thiếu bước 2
SLA xử lý ticket P1?	2/5	3/5	2/5	Retrieve nhầm doc cũ

Baseline
dense-only
chunk 500
top-k=4

→

Variant 1
chỉ đổi chunking

→

Variant 2
thêm hybrid

→

Variant 3
thêm rerank

Nhớ nhanh trước khi code — Indexing checklist

Sprint 1: build index sạch trước khi tune retrieval

1. Preprocess trước khi embed

Clean, extract, normalize để text gọn và nhất quán trước khi vào index.

2. Chunk theo cấu trúc tự nhiên

Ưu tiên heading, section, paragraph; overlap vừa đủ để giữ nghĩa trọn vẹn.

3. Metadata giúp lọc đúng phạm vi

Source, section, effective_date, access level giúp search đúng tài liệu và đúng phiên bản.

4. Sprint 1 Definition of Done

Có script index chạy được và có ít nhất 3 metadata fields hữu ích cho retrieval.

Mẫu metadata tối thiểu

```
metadata = {
  source: policy/refund-v4.pdf,
  section: Điều 3,
  department: CS,
  effective_date: 2026-02-01,
  access: internal
}
```

Checklist tự kiểm trước khi qua Sprint 2

- Text đã sạch và không bị cắt lỗi giữa điều khoản
- Chunk giữ được source và section
- Index phản ánh đúng bộ docs nhóm chọn

Câu nhắc cần nhớ

Chất lượng retrieval bắt đầu từ lúc chuẩn bị tài liệu.
Nếu index bẩn, prompt đẹp cũng chỉ bộc lộ lỗi nhanh hơn.

Nhớ nhanh trước khi code — Retrieval decision map

Sprint 2–3: chọn strategy, top-k và rerank có chủ đích

Quyết định nhanh theo loại query

PARAPHRASE / NGHĨA	Query tự nhiên dài, cần bắt nghĩa gần.	Dense
EXACT TERM / MÃ LỖI	Tên riêng, mã ticket, keyword hiếm cần match chính xác.	Sparse
CORPUS LẪN LỘN	Vừa có câu tự nhiên, vừa có alias, keyword hoặc điều khoản.	Hybrid
TOP-K NHIỄU / LẶP	Search rộng rồi chọn lại tập evidence nhỏ hơn và sạch hơn.	Rerank

Top-k sweet spot

K QUÁ THẤP	VỪA ĐỦ	K QUÁ CAO
thiếu chứng cứ	**top-3 → top-5**	**nhiễu + lãng phí token**

Rerank funnel cần nhớ

SEARCH RỘNG TOP-20 → RERANK TOP-6 → SELECT TOP-3

Khi nào dùng gì?

- Cross-encoder: cần chấm lại chunk nào thực sự trả lời câu hỏi
- MMR: cần giữ relevance nhưng bớt trùng lặp
- Query transformation: chỉ dùng khi query mơ hồ hoặc nhiều alias

Nhớ nhanh trước khi code — Grounded prompt checklist

Sprint 2: answer function phải grounded trước khi demo

4 quy tắc bắt buộc

Evidence-only
Chỉ trả lời từ retrieved context.

Abstain when insufficient
Thiếu chứng cứ thì nói không đủ dữ liệu.

Cite source / section
Output nên gắn nguồn và section khi có thể.

Short, clear, stable
Để còn đo faithfulness và relevance nhất quán.

Prompt skeleton nên có

```
Answer only from the retrieved context.
If the context is insufficient, say you do not know.
Cite the source field when possible.

Question: {query}
Context: {context_block}
```

Kiểm tra nhanh output

- Có citation hoặc source rõ ràng chưa?
- Nếu thiếu context, model có biết dừng đúng cách không?
- Output có đủ ngắn để dễ chấm scorecard không?

Token budget nhớ nhanh

Instruction | Retrieved context | Question | Headroom

Nhớ nhanh trước khi code — Evaluation loop

Sprint 4: test questions, scorecard và A/B tuning phải đi cùng nhau

METRIC 1
Faithfulness

METRIC 2
Relevance

METRIC 3
Context recall / completeness

Evidence bắt buộc để chấm

- 10 test questions
- Expected answer hoặc expected evidence
- Scorecard trước và sau tuning

A/B rule

Baseline → chỉ đổi **một biến** → đo lại.
Đổi đồng thời chunking, hybrid, rerank và prompt thì không biết biến nào tạo cải thiện.

Loop tối thiểu cho Sprint 4

RUN RAG_ANSWER → CHẤM SCORECARD → SO SÁNH BASELINE VS VARIANT

Bước	Câu hỏi tự kiểm
Testset	Có đủ câu hỏi mơ hồ, alias và câu dễ sai không?
Scoring	Điểm faithful / relevant / complete đã có ghi chú chưa?
Variant	Nhóm đang đổi đúng một biến hay đang đổi quá nhiều thứ?
Conclusion	Variant tốt hơn baseline ở điểm nào, bằng chứng nào?

Hands-on 8 — Full RAG Pipeline

4 giờ thực hành: từ index đến evaluation

Sprint 1
60'

Build index với metadata

10–20 docs nhỏ, chunk + metadata + embed + store.

- Có script index chạy được
- Có ít nhất 3 metadata fields hữu ích

Sprint 2
60'

Baseline retrieve + answer

Build retrieval và answer function grounded.

- Trả lời được ít nhất 3 câu hỏi mẫu
- Output có source / citation

Sprint 3
60'

Tuning tối thiểu

Hybrid hoặc rerank hoặc chunking khác.

- Có bảng baseline vs variant
- Giải thích được vì sao chọn biến đó

Sprint 4
60'

Evaluation + docs + report

10 test questions, scorecard, docs kỹ thuật và báo cáo cá nhân.

- Demo chạy end-to-end

Repo tối thiểu

```
index.py rag_answer.py eval.py data/
test_questions.json docs/ architecture.md
tuning-log.md reports/ individual/*.md
```

Deliverables

- Script indexing + retrieval / answer function
- 10 test questions + expected answer/evidence
- Scorecard trước và sau tuning
- docs/architecture.md và docs/tuning-log.md
- Báo cáo cá nhân 500–800 từ / người

Tech lead **Retrieval owner** **Eval owner**

Documentation owner

Hướng dẫn lab 4 giờ — phân vai và cadence làm việc

Tránh một người code, cả nhóm đứng nhìn

Vai trò nên giao ngay ở phút đầu

TECH LEAD

Giữ nhịp sprint, nối code end-to-end, chốt nhánh baseline.

RETRIEVAL OWNER

Chăm Sprint 1–3: chunking, metadata, retrieval strategy, rerank.

EVAL OWNER

Quản test questions, expected evidence, scorecard, A/B comparison.

DOCUMENTATION OWNER

Chốt docs/architecture, tuning log và báo cáo cá nhân cho cả nhóm.

Nhịp làm việc gợi ý

Mỗi sprint 60 phút nên kết thúc bằng một mốc quan sát được: script chạy, output có citation, scorecard trước/sau, docs cập nhật.

Sprint ownership map

Sprint	Ai lead	Kết quả phải chốt
1 · Index	Tech lead + Retrieval owner	Index chạy được, metadata đủ dùng
2 · Baseline	Tech lead	Answer function grounded + source/citation
3 · Tuning	Retrieval owner + Eval owner	1 variant rõ ràng + lý do chọn biến
4 · Eval & docs	Eval owner + Documentation owner	Scorecard, docs kỹ thuật, report cá nhân

Rule để đỡ tắc

Không chờ “xây xong hết rồi mới eval”. Baseline phải chạy sớm để còn so sánh với variant.

Hướng dẫn lab 4 giờ — file cần có & checklist nộp bài

Repo structure, deliverables nhóm và báo cáo cá nhân

Repo tối thiểu

```
project/
  index.py
  rag_answer.py
  eval.py
  data/test_questions.json
  docs/architecture.md
  docs/tuning-log.md
  reports/individual/*.md
```

Rubric chấm nhanh

- 45% code chạy end-to-end
- 25% tài liệu kỹ thuật
- 20% bằng chứng chất lượng / scorecard
- 10% báo cáo cá nhân

Checklist nộp bài theo nhóm

Nhóm artifact	Những gì phải có
Code + data	Script indexing, retrieval / answer function, bộ docs đã index
Eval artifact	10 test questions, expected answer / evidence, scorecard trước & sau tuning
Documentation	Architecture.md, tuning-log.md, giải thích vì sao variant tốt hơn baseline

Checklist báo cáo cá nhân

1. Tôi phụ trách phần nào trong nhóm?
2. Tôi đã sửa một lỗi hoặc ra một quyết định kỹ thuật gì?
3. Kết quả đo được hoặc bằng chứng trước / sau là gì?
4. Nếu có thêm 2 giờ, tôi sẽ cải thiện gì?

Key takeaways & cầu nối sang Day 09

Từ trả lời grounded sang hệ thống có nhiều vai trò

1. **RAG tốt** là phối hợp đúng giữa indexing, retrieval và generation.
2. **Retrieval quality** thường quan trọng hơn generation polish.
3. **Hybrid + rerank + scorecard** là ba đòn bẩy practical để tuning.
4. **Artifact hôm nay không bị bỏ đi**; nó sẽ trở thành worker hoặc capability trong hệ multi-agent ngày mai.

Bridge diagram

DAY 08

RAG Agent

retrieve + answer grounded

→

DAY 09

Supervisor

route + state + trace

Retrieval | **Tool** | **Synthesis**

Day 09 · MCP / A2A / LangGraph

Câu hỏi mở

Nếu tách artifact hôm nay thành 2–3 worker, bạn sẽ chia theo **bước xử lý** hay theo **tool / domain**?